

Causal Inference in Non-linear Time-series using Deep Networks and Knockoff Counterfactuals

Махин Артем, 417 группа

<https://arxiv.org/pdf/2109.10817.pdf>

18.10.20201

Causal Inference

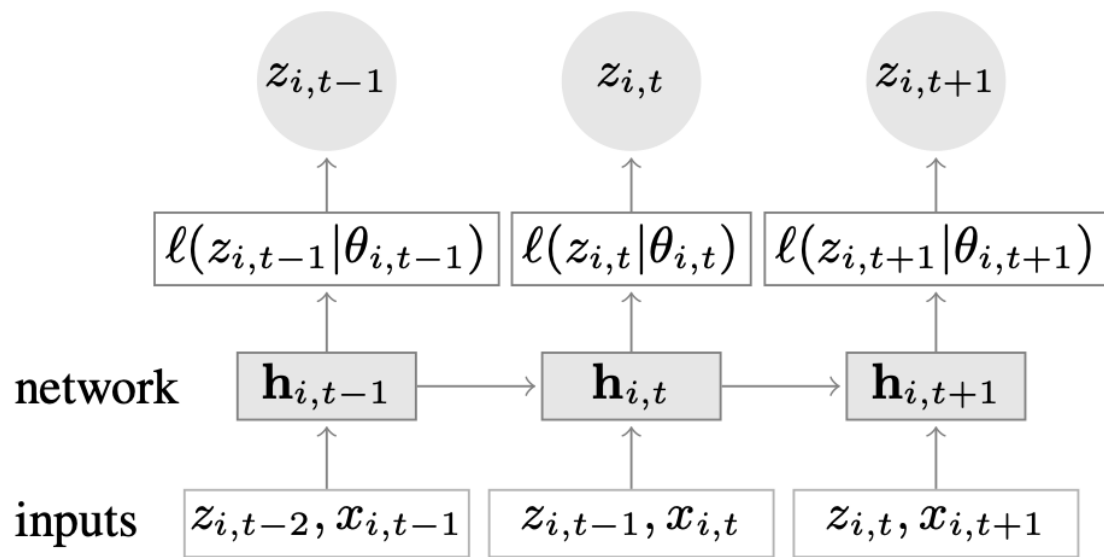
Причинно-следственный вывод

При причинном выводе человек делает вывод о том, что что-то является или может быть причиной чего-то еще.

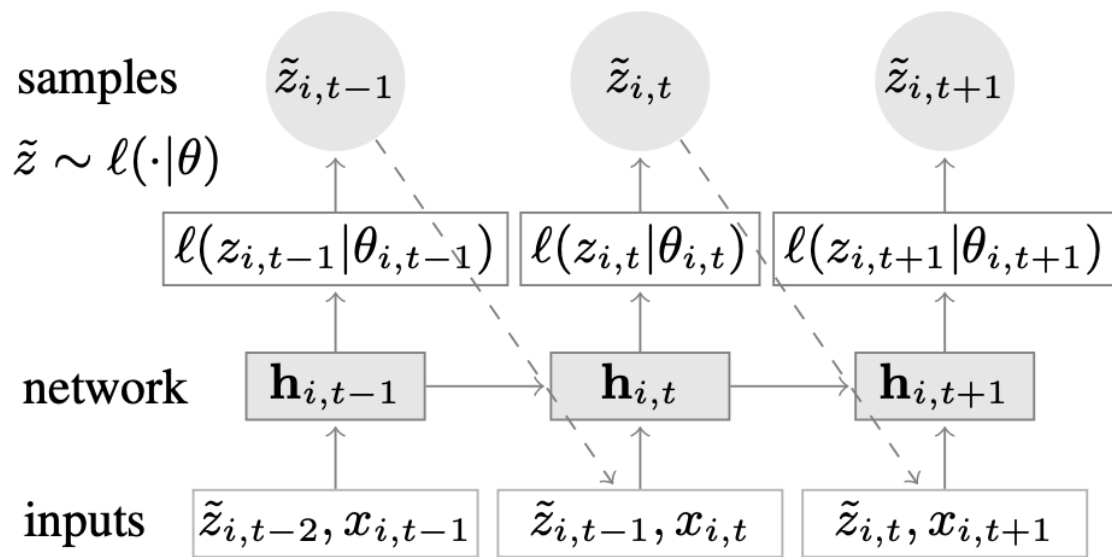


Deep AR

Amazon, 2019



Train



Forecast

Deep AR

Amazon, 2019

Максимизируем логарифм правдоподобия:

$$\mathcal{L} = \sum_{i=1}^N \sum_{t=t_0}^T \log \ell(z_{i,t} | \theta(\mathbf{h}_{i,t})) .$$

Deep AR

Amazon, 2019

Максимизируем логарифм правдоподобия: $\mathcal{L} = \sum_{i=1}^N \sum_{t=t_0}^T \log \ell(z_{i,t} | \theta(\mathbf{h}_{i,t}))$.

Пример: $\theta = (\mu, \sigma)$

$$\ell_G(z | \mu, \sigma) = (2\pi\sigma^2)^{-\frac{1}{2}} \exp(-(z - \mu)^2 / (2\sigma^2))$$


$$\mu(\mathbf{h}_{i,t}) = \mathbf{w}_\mu^T \mathbf{h}_{i,t} + b_\mu \quad \text{and} \quad \sigma(\mathbf{h}_{i,t}) = \log(1 + \exp(\mathbf{w}_\sigma^T \mathbf{h}_{i,t} + b_\sigma))$$

Deep AR

Особенности обучения

Масштабирование: $\nu_i = 1 + \frac{1}{t_0} \sum_{t=1}^{t_0} z_{i,t}$

Обучение окнами:



Sequence to Sequence Encoder-Decoder

Deep AR

Свойства

1

DeepAR эффективен при прогнозировании сезонных зависимостей с минимальной настройкой

2

Deep AR делает вероятностный прогноз

3

DeepAR может использовать ряды с небольшой историей

4

DeepAR поддерживает широкий спектр функций правдоподобия

$$Z = (Z_1, \dots, Z_n) \quad \begin{array}{c} \rightarrow \\ \leftarrow \end{array} \quad \tilde{Z} = (\tilde{Z}_1, \dots, \tilde{Z}_n)$$

$$(Z, \tilde{Z})_{\text{swap}(\mathbb{A})} \stackrel{d}{=} (\tilde{Z}, Z) \quad \text{для любого } \mathbb{A} \subseteq 1, \dots, n$$

$$Z = (Z_1, \dots, Z_n) \quad \begin{array}{c} \rightarrow \\ \leftarrow \end{array} \quad \tilde{Z} = (\tilde{Z}_1, \dots, \tilde{Z}_n)$$

$$(Z, \tilde{Z})_{\text{swap}(\mathbb{A})} \stackrel{d}{=} (\tilde{Z}, Z) \quad \text{для любого } \mathbb{A} \subseteq 1, \dots, n$$

Пример: $P_Z = \mathcal{N}_n(\mathbf{0}_n, \Sigma)$

$$P_{\tilde{Z}|Z}(\cdot | \mathbf{Z}_{i,*}) = \mathcal{N}_n((\mathbf{I}_n - S\Sigma^{-1})\mathbf{Z}_{i,*}, 2S - S\Sigma^{-1}S)$$

для любой фиксированной матрицы S , удовлетворяющей $0 \leq S \leq 2\Sigma$.

Causal effect estimation

$z_{i,t}, t = 1, \dots, r, i = 1, \dots, N$ реализации длины r процессов $Z_i, i = 1, \dots, N$

$$\text{MAPE} = \frac{1}{r} \sum_{t=1}^r \frac{|z_{i,t} - \hat{z}_{i,t}|}{|z_{i,t}|}$$

Causal significance score: $\text{CSS}_{i \rightarrow j} = \ln \frac{\text{MAPE}_j^i}{\text{MAPE}_j}$

Чем заменять?



Knockoffs (DeepKnockoffs)



Mean $\bar{z}_i = \frac{1}{r} \sum_{t=1}^r z_{i,t}$



Out-of-distribution

VAR GC

vector autoregressive Granger Causality

$z_{i,t}, t = 1, \dots, r, i = 1, \dots, N$ реализации длины r процессов $Z_i, i = 1, \dots, N$

$$\begin{bmatrix} z_{1,t} \\ \vdots \\ z_{N,t} \end{bmatrix} = \sum_{m=1}^p A_m \begin{bmatrix} z_{1,t-m} \\ \vdots \\ z_{N,t-m} \end{bmatrix} + \begin{bmatrix} \epsilon_1(t) \\ \vdots \\ \epsilon_N(t) \end{bmatrix}$$

VAR GC

vector autoregressive Granger Causality

$z_{i,t}, t = 1, \dots, r, i = 1, \dots, N$ реализации длины r процессов $Z_i, i = 1, \dots, N$

$$\begin{bmatrix} z_{1,t} \\ \vdots \\ z_{N,t} \end{bmatrix} = \sum_{m=1}^p A_m \begin{bmatrix} z_{1,t-m} \\ \vdots \\ z_{N,t-m} \end{bmatrix} + \begin{bmatrix} \epsilon_1(t) \\ \vdots \\ \epsilon_N(t) \end{bmatrix}$$

$$\sum_j (\epsilon_j, z_j)$$

$$\sum_j^{i-} (\epsilon_j, z_j)$$



$$\text{VAR-GC}(z_i, z_j) : \gamma_{i \rightarrow j} = \ln \frac{|\sum_j^{i-}|}{|\sum_j|}$$

Эксперименты

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

$$\text{F-score} = \frac{\text{TP}}{\text{TP} + 0.5(\text{FP} + \text{FN})}$$

Эксперименты

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

$$\text{F-score} = \frac{\text{TP}}{\text{TP} + 0.5(\text{FP} + \text{FN})}$$

$$X_1(t) = \mathcal{N}(0, 1) + |\cos(2\pi ft)|$$

$$X_2(t) = c_1 X_2(t - \tau_1) + c_2 X_1(t - \tau_2) + \eta_1(t)$$

$$X_3(t) = c_3 X_1(t - \tau_3) * X_2(t - \tau_4) + \eta_2(t)$$

$$X_4(t) = c_4 X_3(t - \tau_5) * \beta^{\frac{X_2(t - \tau_6) - Q}{10}} + \eta_3(t)$$



$$c = [0.95, 0.80, 0.50, 0.75]$$

$$Q = 10$$

$$f = 150$$

$$0 \leq t \leq 3000$$

Эксперименты



Эксперименты


Реальные данные

Causal links	Expected	VAR-GC	PCMCI	DeepAR-Knockoffs
$K_t \rightarrow D_t$	Yes	Yes	Yes	Yes
$K_t \rightarrow L_t$	No	Yes	Yes	No
$D_t \rightarrow K_t$	No	Yes	Yes	No
$D_t \rightarrow L_t$	No	Yes	No	No
$L_t \rightarrow K_t$	No	Yes	Yes	No
$L_t \rightarrow D_t$	No	No	No	Yes

Небольшая реклама

ETNA Time Series Library

Многофункциональный удобный инструмент для работы с временными рядами



Небольшая реклама



- Большой зоопарк моделей, ансамбли
 - Куча препроцессингов и расчетов признаков
 - Много EDA
 - Интеграция с Weights and Biases
 - Работа с доп данными
 - Возможность внедрять свои модели и трансформы
 - Кластеризация рядов
 - Поиск и обработка аномалий
 - Работа с несколькими сегментами
 - Визуализация всего что только можно
 - Отбор признаков
 - Подбор гиперпараметров
 - Causal inference
- ● ●

Весь пайплайн

```
original_df = pd.read_csv("data/example_dataset.csv")
df = TSDataset.to_dataset(original_df)
ts = TSDataset(df, freq='D')

log = LogTransform(in_column="target")
trend = LinearTrendTransform(in_column="target")
seg = SegmentEncoderTransform()
lags = LagTransform(in_column="target", lags=list(range(30, 96, 1)))
d_flags = DateFlagsTransform(day_number_in_week=True,
                             day_number_in_month=True,
                             week_number_in_month=True,
                             week_number_in_year=True,
                             month_number_in_year=True,
                             year_number=True,
                             special_days_in_week=[5, 6])

train_ts, test_ts = ts.train_test_split(train_start='2019-01-01',
                                         train_end='2019-11-30',
                                         test_start='2019-12-01',
                                         test_end='2019-12-31')

train_ts.fit_transform([log, trend, lags, d_flags, seg])

model = CatBoostModelMultiSegment()
model.fit(train_ts)
future_ts = train_ts.make_future(HORIZON)
forecast_ts = model.forecast(future_ts)
```

ETNA



https://t.me/etna_support

<https://github.com/tinkoff-ai/etna-ts>

<https://etna.tinkoff.ru>